

Univerzita Jana Evangelisty Purkyně
v Ústí nad Labem
Přírodovědecká fakulta



Vliv předzpracování obrazu a augmentace dat
na segmentaci rentgenových snímků

DIPLOMOVÁ PRÁCE

Vypracoval: Bc. Milan Gittler

Vedoucí práce: RNDr. Jíří Škvára, Ph.D.

Studijní program: Aplikovaná informatika

ÚSTÍ NAD LABEM 2024

Namísto žlutých stránek vložte digitálně podepsané zadání kvalifikační práce poskytnuté vedoucím katedry.

Zadání musí zaujímat právě dvě strany.

Zadání je nutno vložit jako PDF pomocí některého nástroje, který umožňuje editaci dokumentů (se zachováním elektronického podpisu).

V Linuxe lze například použít příkaz `pdftk`.

Prohlášení

Prohlašuji, že jsem tuto diplomovou práci vypracoval samostatně a použil jen pramenů, které cituji a uvádím v přiloženém seznamu literatury.

Byl jsem seznámen s tím, že se na moji práci vztahují práva a povinnosti vyplývající ze zákona c. 121/2000 Sb., ve znění zákona c. 81/2005 Sb., autorský zákon, zejména se skutečností, že Univerzita Jana Evangelisty Purkyně v Ústí nad Labem má právo na uzavření licenční smlouvy o užití této práce jako školního díla podle § 60 odst. 1 autorského zákona, a s tím, že pokud dojde k užití této práce mnou nebo bude poskytnuta licence o užití jinému subjektu, je Univerzita Jana Evangelisty Purkyně v Ústí nad Labem oprávněna ode mne požadovat přiměřený příspěvek na úhradu nákladu, které na vytvoření díla vynaložila, a to podle okolností až do jejich skutečné výše.

V Ústí nad Labem dne 29. března 2024

Podpis:

Děkuji vedoucímu práce RNDr. Jiřímu Škvárovi, Ph.D.
za neocenitelné rady a pomoc při tvorbě diplomové práce.

Abstrakt:

Hlavním cílem této diplomové práce je seznámit čtenáře s

Klíčová slova: lorem, ipsum, dolor, sit, amet

IMPACT OF IMAGE PREPROCESSING AND DATA AUGMENTATION ON SEGMENTATION OF X-RAY IMAGES

Abstract:

lorem ipsum dolor sit amet

Keywords: lorem, ipsum, dolor, sit, amet

Obsah

Úvod	13
1. Přehled metod předzpracování obrazu	15
1.1. Klasické metody předzpracování obrazu	15
1.2. Neuronové sítě pro předzpracování obrazu	20
1.3. Obecné postupy augmentace dat	20
2. Placeholder	21
2.1. Popis úlohy	21
2.2. Načtení a transformace dat	21
2.3. Vizualizace dat	21
2.4. Tvorba modelů	21
2.5. Evaluace modelů	21
3. Zhodnocení	23
4. Závěr	25
A. Externí přílohy	33

Úvod

1. Přehled metod předzpracování obrazu

V této kapitole se zaměříme na představení klíčových metod předzpracování obrazu, které hrají zásadní roli v procesu analýzy a zpracování rentgenových snímků. Předzpracování obrazu představuje kritický krok v řadě aplikací strojového učení a počítačového vidění, neboť ovlivňuje kvalitu a efektivitu následné analýzy. Metody předzpracování obrazu mohou výrazně zlepšit kvalitu dat a zvýšit přesnost detekce objektů, segmentace obrazu či klasifikace. Specifický výběr těchto technik je klíčový pro zjištění přesnosti a efektivity moderních metod počítačového vidění, včetně strojového učení a hlubokého učení, které jsou stále častěji aplikovány na širokou škálu problémů v oblasti zpracování obrazu. Zejména v kontextu rentgenových snímků může předzpracování pomoci překonat některé běžné výzvy, jako je nízký kontrast, šum, nebo artefakty, které mohou snížit kvalitu obrazu a tím ovlivnit diagnózu nebo automatickou analýzu.[1]

1.1. Klasické metody předzpracování obrazu

Následující sekce se zabývá představením klasických metod a technik, které jsou využívány pro úpravu a zlepšení kvality obrazových dat před jejich dalším zpracováním. Budeme se tedy věnovat různým přístupům filtrace obrazu, metodám redukce šumu či zaostření obrazu a také technikám prahování a binarizace, které jsou fundamentální pro analýzu a interpretaci obrazových dat. Přestože se jedná o metody, které mohou být považovány za základní, jejich správná aplikace a kombinace mohou výrazně zlepšit výslednou kvalitu obrazu a přispět k efektivnějšímu rozpoznávání vzorů a objektů v obrazových datech. Podrobně prozkoumáme každou z těchto metod, přičemž budeme klást důraz na jejich význam pro přípravu dat k dalšímu zpracování.

Vylepšení obrazu

Vylepšení obrazu je klíčovou technikou v předzpracování obrazu, zaměřenou na zlepšení vizuální kvality obrazových dat pro následné zpracování nebo analýzu. Vylepšení obrazu usiluje o zlepšení kontrastu, jasu a ostrosti, aby bylo zajištěno, že obrazová data jsou co nejvíce přístupná pro lidské vnímání nebo automatizované algoritmy. Jedním z klíčů k úspěšnému zlepšení obrazu je výběr vhodné metody a jejích parametrů, které musí být pečlivě nastaveny v závislosti na charakteristikách obrazových dat a konkrétním účelu zpracování.

Ekvalizace histogramu

Ekvalizace histogramu je fundamentální, ale mocná technika, která se používá pro zlepšení kontrastu v obrazových datech, zejména tam, kde původní obraz obsahuje špatně rozlišitelné detaily kvůli nedostatečnému rozsahu intenzit pixelů.

Cílem ekvalizace histogramu je aplikovat transformaci na původní histogram obrazu, $H(i)$, kde i představuje intenzitu pixelů v původním obrazu, tak, aby výsledný histogram měl uniformní rozložení. Tato transformace je založena na kumulativní distribuční funkci (CDF), $CDF(i)$, vypočítané z původního histogramu. $CDF(i)$ představuje součet pravděpodobností všech intenzit pixelů od nejnižší hodnoty až po intenzitu i a slouží jako mapovací funkce pro přiřazení nových intenzit pixelů ve výsledném obraze. Matematicky lze CDF definovat jako $CDF(j) = \sum_{i=0}^j P(i)$, kde $P(j)$ je pravděpodobnost výskytu intenzity j v původním obrazu, což se obvykle určí normalizací histogramu na celkový počet pixelů v obraze. Nová intenzita pixelu i' pro každý pixel s původní intenzitou i ve výsledném obraze je poté určena pomocí normalizované CDF, což zajišťuje, že všechny intenzity jsou rovnoměrně zastoupeny:

$$i' = (L - 1) \cdot CDF(i) \quad (1.1)$$

kde: L = je počet možných úrovní intenzity pixelů (např. $L = 256$ pro 8bitové obrazy)

Tímto způsobem transformace zvýší kontrast obrazu tak, že "roztáhne" rozložení intenzit pixelů přes celý dostupný rozsah, což zvýrazní detaily a zlepší vizuální vnímání obrazu. Ekvalizace histogramu tak přináší výrazné zlepšení v oblastech s nízkým kontrastem a umožňuje lepší vizualizaci detailů, což je zásadní pro dalšího zpracování obrazu. [2] [3]

Algoritmus 1 Ekvalizace histogramu

- 1: **Vstup:** Původní obraz Img
 - 2: **Výstup:** Obraz s ekvalizovaným histogramem Img_{eq}
 - 3: Vypočítejte histogram H z Img
 - 4: Vypočítejte kumulativní histogram CH z H
 - 5: Normalizujte CH na rozsah intenzit pixelů obrazu
 - 6: **for** každý pixel p v Img **do**
 - 7: Nastavte $Img_{eq}[p]$ na hodnotu odpovídající $CH[Img[p]]$
 - 8: **end for**
 - 9: **return** Img_{eq}
-

Adaptivní ekvalizace histogramu

Adaptivní ekvalizace histogramu (AHE) představuje pokročilou metodu ekvalizace, která se snaží zlepšit kontrast obrazu lokálně, na rozdíl od globálního přístupu klasické ekvalizace histogramu. AHE algoritmus rozdělí původní obraz na malé, překrývající se bloky, nazývané dlaždice (tiles), a na každou z nich aplikuje ekvalizaci histogramu nezávisle. Tímto způsobem dokáže lépe zachytit lokální kontrastní charakteristiky obrazu a zvýraznit detaily v jednotlivých oblastech. Při překryvu

dlaždic se výsledné intenzity pixelů na okrajích vypočítají jako vážený průměr z odpovídajících intenzit získaných z každé příslušné dlaždice, což zajišťuje hladký přechod mezi dlaždicemi. [4]

Adaptivní ekvalizace histogramu s omezením kontrastu

Adaptivní ekvalizace histogramu s omezením kontrastu (CLAHE) byla vyvinuta s cílem předejít problémům spojeným s přílišným zvýrazněním šumu v homogenních oblastech obrazu, které nastává při použití AHE.

Základní myšlenka CLAHE spočívá v rozdělení obrazu na malé, kontextově závislé bloky a aplikování ekvalizace histogramu na každý z těchto bloků. Aby se zabránilo nežádoucímu efektu nadměrného zvýšení kontrastu, aplikuje se na histogram každého bloku proces „osekání“ (clipping), kdy hodnoty histogramu přesahující předem definovaný limit jsou sníženy na tento limit a přebytečné hodnoty jsou rovnoměrně rozděleny mezi ostatní úrovně intenzity. To vede k vytvoření vyváženějšího rozložení intenzit v obrazu a zajišťuje, že zvýšení kontrastu nevede k nežádoucímu zvýraznění šumu.

Jedním z klíčových aspektů CLAHE je výběr „clip limitu“, což je parametr, který omezuje míru zvýšení kontrastu. Tento limit se obvykle definuje jako násobek průměrné hodnoty histogramu a jeho správné nastavení je zásadní pro dosažení optimálního výsledku. [4]

Unsharp masking

Unsharp masking je technika určená k zlepšení ostrosti obrazu tím, že zvýrazňuje hrany a detaily, které jsou v původním obrazu méně patrné. Klíčovým krokem této metody je vytvoření tzv. masky ostrých detailů odečtením rozmazané verze obrazu od jeho původní podoby. Rozmazaná verze obrazu se získává například pomocí Gaussova filtru, který je aplikován na původní obraz. Intenzita tohoto rozmazání určuje, jak silně budou hrany a detaily v maskě zvýrazněny. [5]

Algoritmus 2 Unsharp Masking

- 1: **Vstup:** Původní obraz I , standardní odchylka Gaussova filtru σ , zesílení λ
 - 2: **Výstup:** Vylepšený obraz I'
 - 3: $G \leftarrow \text{Gauss}(I, \sigma)$ ▷ Vytvoření rozmazané verze obrazu pomocí Gaussova filtru
 - 4: $M \leftarrow I - G$ ▷ Vytvoření masky ostrých detailů odečtením rozmazaného obrazu
 - 5: $I' \leftarrow I + \lambda M$ ▷ Zvýšení ostrosti původního obrazu přičtením masky
-

V tomto procesu:

- σ určuje míru rozmazání při použití Gaussova filtru.
- λ je koeficient zesílení, který kontroluje míru, jakou jsou detaily zvýrazněny při přičítání masky k původnímu obrazu.

Při použití unsharp masking metody může vznikat nežádoucí halo efektu. Tento efekt se projevuje jako nežádoucí světlý okraj kolem kontrastních hran, což může vést k umělému a nepřírozenému vzhledu obrazu. Integrace filtru zachovávajícího hrany (edge-preserving filter) do procesu unsharp

masking je klíčová pro minimalizaci zmíněného efektu. Tento filtr umožňuje zvýraznit hrany a detaily v obrazu, aniž by docházelo k nežádoucím artefaktům. [5]

Unsharp masking metoda je vhodná pro aplikace, kde je žádoucí zlepšit viditelnost detailů a hran. Důležitým aspektem při použití unsharp masking je správný výběr parametrů σ a λ , jelikož tyto hodnoty významně ovlivňují výsledný vzhled obrazu. Příliš vysoké hodnoty mohou vést k nežádoucím artefaktům, jako jsou halo efekty kolem hran, zatímco příliš nízké hodnoty mohou mít za následek nedostatečné zvýraznění detailů.

Gama korekce

Gamma korekce je technika používaná k úpravě jasu obrazových dat. Principem této metody je aplikace nelineární transformace na původní pixelové hodnoty obrazu, čímž se upravuje celková jasová křivka podle gamma funkce. Tato korekce umožňuje efektivněji využít dynamický rozsah zobrazovacích zařízení a zlepšit viditelnost detailů v tmavých i světlých oblastech obrazu bez ztráty informací v ostatních částech obrazového spektra. [6]

Aplikace gamma korekce se obvykle provádí podle vzorce:

$$I' = I^\gamma \quad (1.2)$$

kde: I = původní intenzita pixelu

I' = nová intenzita pixelu po aplikaci gamma korekce

γ = gamma faktor, který určuje míru korekce

Hodnota gamma faktoru menší než 1 zvýší jas tmavších oblastí obrazu, zatímco hodnota větší než 1 ztmaví světlejší oblasti a zvýší kontrast.

Redukce šumu

Redukce šumu ve snímcích je zásadní proces v digitálním zpracování obrazu, který má za cíl odstranit nebo minimalizovat vliv šumu přidaného během akvizice nebo přenosu obrazových dat. Šum může být způsoben různými externími faktory a může výrazně snížit kvalitu a čitelnost snímků, což má negativní dopad na jejich další analýzu a interpretaci.

Šum je obvykle definován jako náhodná variace intenzity obrazových bodů (pixelů), která se projevuje jako viditelné zrnění nebo textura na snímku. Tato náhodná variabilita může být důsledkem základních fyzikálních procesů, jako je povaha fotonu světla nebo tepelná energie v senzorech obrazu. Může vzniknout v okamžiku snímání nebo při přenosu obrazu.

Jednoduchý matematický model, kterým lze vyjádřit přítomnost aditivního šumu v obrazu, můžeme definovat jako:

$$f(x, y) = I(x, y) + N(x, y) \quad (1.3)$$

kde: $f(x, y)$ = je pozorovaná intenzita pixelu se šumem

$I(x, y)$ = je skutečná intenzita pixelu bez šumu

$N(x, y)$ = je hodnota šumu přidaná k pixelu.

Redukce šumu je proto klíčovým krokem ve zpracování obrazu, který pomáhá zlepšit celkovou kvalitu snímků tím, že vyhlazuje obraz a odstraňuje nepřesnosti, avšak s opatrností, aby nedošlo k ztrátě důležitých detailů nebo hran v obrazu. Efektivní algoritmy pro redukci šumu se snaží dosáhnout rovnováhy mezi odstraněním šumu a zachováním nebo dokonce zvýrazněním důležitých vlastností obrazu, jako jsou hrany nebo textury. [7, 8]

Typy šumu ve snímcích

Existuje několik typů šumu, které se mohou ve snímcích vyskytovat. Tyto šумы se liší svým původem, charakteristikami a vlivem na kvalitu obrazu. Pro účinnou redukci šumu je klíčové rozpoznat, s jakým typem šumu máme co do činění, aby bylo možné zvolit nejvhodnější metodu pro jeho odstranění. Níže jsou uvedeny některé z nejčastějších typů šumu, které mohou ovlivnit digitální snímky. [7]

- **Gaussovský šum** je pravděpodobně nejrozšířenějším typem šumu v digitálních obrazových systémech, způsobený především elektronickými fluktuacemi v senzoru a obvodech kamery. Je charakterizován normálním rozdělením intenzit pixelů kolem skutečné hodnoty s určitou střední hodnotou a standardní odchylkou.

$$P(n) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(n-\mu)^2}{2\sigma^2}}$$

Gaussovský šum je obvykle považován za aditivní šum, což znamená, že jeho hodnota je nezávisle přídána k intenzitě každého pixelu.

- **Impulzní šum (Šum soli a pepře)** se projevuje jako náhodné černé nebo bílé (nebo obojí) pixely rozptýlené po celém obrazu. Tento typ šumu může vzniknout kvůli chybám v senzoru nebo při přenosu dat. Na rozdíl od Gaussovského šumu je impulzní šum typicky nelineární a jeho redukce vyžaduje specifické nelineární filtrační techniky.
- **Poissonův šum** je typ šumu, který je často přítomen v obrazových datech získaných z nízkých intenzit světla, jako jsou rentgenové snímky nebo mikroskopické snímky. Poissonův šum je důsledkem náhodného procesu počtu fotonů, které dopadají na senzor, a je charakterizován jako náhodný proces s diskrétním rozdělením pravděpodobnosti. Redukce Poissonova šumu vyžaduje specifické metody, které jsou schopny zacházet s diskrétními daty a zároveň zachovat důležité detaily v obraze. Poissonův šum může být modelován jako:

$$P(n) \sim \frac{e^{-\lambda} \lambda^n}{n!}$$

- **Speckle šum** se řadí do skupiny multiplikativních šumů, které jsou často přítomny v ultrazvukovém a radarovém zobrazování. Tento šum je důsledkem koherence vlnění použitého pro snímání a interferencí mezi rozptýlenými vlnami. Speckle šum může být modelován pomocí Rayleighova nebo Gamma rozdělení v závislosti na povaze obrazových dat.

Prahování a binarizace

1.2. Neuronové sítě pro předzpracování obrazu

Přehled a principy

1.3. Obecné postupy augmentace dat

2. Placeholder

2.1. Popis úlohy

2.2. Načtení a transformace dat

2.3. Vizualizace dat

2.4. Tvorba modelů

2.5. Evaluace modelů

3. Zhodnocení

4. Závěr

Seznam použitých zdrojů

1. BASAVAPRASAD, Benchamardimath; RAVINDRA, Hegadi. A STUDY ON THE IMPORTANCE OF IMAGE PROCESSING AND ITS APLPLICATIONS. *International Journal of Research in Engineering and Technology* [online]. 2014, **03**(15), 155–160 [cit. 2024-03-16]. ISSN 23217308. Dostupné z DOI: 10.15623/ijret.2014.0315029.
2. KRIG, Scott. *Computer Vision Metrics*. 1. vyd. California: Apress Berkeley, 2014. ISBN 978-1-4302-5930-5. Dostupné z DOI: 10.1007/978-1-4302-5930-5.
3. *Computer Vision for X-Ray Testing: Imaging, Systems, Image Databases, and Algorithms*. 1. vyd. Cham: Springer International Publishing, 2015. ISBN 978-3-319-20747-6. Dostupné z DOI: 10.1007/978-3-319-20747-6.
4. Contrast Limited Adaptive Histogram Equalization. In: *Graphics Gems IV*. 1st Edition. San Francisco: Academic Press, 1994, s. 474–485. ISBN 978-0-12-336155-4.
5. JAYAKUMAR, Dontabhaktuni; PULLARAO, Bandi; PRADEEP, Vanukuru. An Algorithm on Generalized Un Sharp Masking for Sharpness and Contrast of an Exploratory Data Model. *International Journal of Advanced Engineering Research and Science*. 2016, **3**(9), 62–72. ISSN 23496495. Dostupné z DOI: 10.22161/ijaers/3.9.10.
6. CHAKI, Jyotismita; DEY, Nilanjan. *A Beginner's Guide to Image Preprocessing Techniques*. 1st Edition. Boca Raton: CRC Press, 2018. ISBN 9780429441134. Dostupné z DOI: 10.1201/9780429441134.
7. FAN, Linwei; ZHANG, Fan; FAN, Hui; ZHANG, Caiming. Brief review of image denoising techniques. *Visual Computing for Industry, Biomedicine, and Art* [online]. 2019, **2**(1) [cit. 2024-03-29]. ISSN 2524-4442. Dostupné z DOI: 10.1186/s42492-019-0016-7.
8. HAMBAL, Abdalla Mohamed; PEI, Zhijun; ISHABAILU, Faustini Libent. Image Noise Reduction and Filtering Techniques. *International Journal of Science and Research (IJSR)* [online]. 2017, **6**, 2033–2038 [cit. 2024-03-29]. Dostupné z: <https://www.ijsr.net/getabstract.php?paperid=25031706>.

Seznam obrázků

Sazba zdrojových kódů

A. Externí přílohy

Struktura repozitáře je následující:

BostonHousing	vypracovaná regresní úloha a data set Boston Housing
IrisFlowers	vypracovaná klasifikační úloha a data set Iris flowers
Obrázky	adresář s obrázky, které jsou zobrazeny v repozitáři
IntrusionDetection.rar	vypracovaná úloha Intrusion detection s data sety v souboru rar
README.md	jednoduchý popis repozitáře
